Tutorium 11: Parallelprogrammierung mit MPI

Paul Brinkmeier

13. Januar 2020

Tutorium Programmierparadigmen am KIT

EULENFEST 23.01.2020

Infobau 50.34 ab 19 Uhr

Helfer werden!
https://www.redseat.de/eulenfest20/

Heutiges Programm

Parallelprogrammierung

ProPa-Stoff zu Parallelprogrammierung:

- Grundlegende Begriffe
- Message Passing, wurde in OS *kurz* behandelt („message queues“)
- Shared Memory + Synchronisierung, wie in SWT1, OS, etc.
    - In Java, mit ein paar Details zur JVM

Begriffe

Flynns Taxonomie

- SISD: Single Instruction, Single Data

  Ein Datum wird von einer Ausführungsarbeit bearbeitet
- SIMD: Single Instruction, Multiple Data

  Eine Ausführungseinheit bearbeitet mehrere Daten gleichzeitig
- MIMD: Multiple Instruction, Multiple Data

  $\approx$ Mehrere Ausführungseinheiten arbeiten gleichzeitig
- MISD: Multiple Instruction, Single Data

  $\approx$ Mehrere Ausführungseinheiten arbeiten gleichzeitig an einem Datum

Flynns Taxonomie

- SISD: Single Instruction, Single Data

  Ein Datum wird von einer Ausführungsarbeit bearbeitet
- SIMD: Single Instruction, Multiple Data

  Eine Ausführungseinheit bearbeitet mehrere Daten gleichzeitig
- MIMD: Multiple Instruction, Multiple Data

  $\approx$ Mehrere Ausführungseinheiten arbeiten gleichzeitig
- MISD: Multiple Instruction, Single Data

  $\approx$ Mehrere Ausführungseinheiten arbeiten gleichzeitig an einem Datum

Beispiele?

Daten- und Taskparallelismus

Parallele Probleme sind üblicherweise entweder

- „datenparallel“: Problem kann auf identische Ausführungseinheiten verteilt werden
  Beispiel: `map primeFactors [1432793, 651433, ...]`
- „taskparallel“: Problembestandteile sind nicht homogen
  Beispiel: Videospiel mit Render-, Netzwerk- und Logikprozessen

Datenparallele Probleme sind i.d.R. einfacher zu behandeln (auch: „embarrassingly parallel“). Bei manchen Problemen verschwimmt die Grenze auch (bspw. Webserver).

MPI-Basics

MPI

MPI („Message Passing Interface“) ist ein Standard für Parallelprogrammierung. Es existieren verschiedene Implementierungen für verschiedene Sprachen. Die VL verwendet Open MPI, eine Open-Source-Implementierung.

- MPI-„Prozesse“ beziehen sich i.d.R. auf Prozessorkerne
- Man verwendet Message Passing statt Shared Memory
  - Daten werden explizit über `Send` und `Recv` geteilt
- MPI-Prozesse werden in sog. *Communicators* eingeteilt. Wir verwenden immer den Communicator, der alle Prozesse enthält (`MPI_COMM_WORLD`))

Installation von MPI

MPI-Beispiel gehen von Linux-Systemen aus, verwendet unter Windows bitte WSL.

- `apt install openmpi-bin` (Ubuntu)
- `pacman -S openmpi` (Arch Linux)
- `dnf install openmpi` (Fedora)

Dann `mpicc --version` zum Testen der Installation.

Bauen und Ausführen von MPI-Programmen

MPI-Programme werden mit `mpicc` (Wrapper um `gcc`) kompiliert:

```
cd demos/mpi/hello
mpicc -o hello hello.c # oder make
```

Um ein Programm auszuführen, wird `mpirun` verwendet:

```
mpirun [--oversubscribe] -np [N] ./hello
```

- `N` ist die Zahl der Prozesse, die ausgeführt werden sollen
- `--oversubscribe` braucht ihr, falls `N` größer als die Zahl eurer Prozessorkerne ist
- Vergleicht die Ausgabe der Demos `hello` und `sendrecv`

Send/Recv

Per `Send` und `Recv` werden Daten zwischen Prozessen ausgetauscht.
Die Aufrufe sind unabhängig vom Medium (IPC, Sockets, ...).

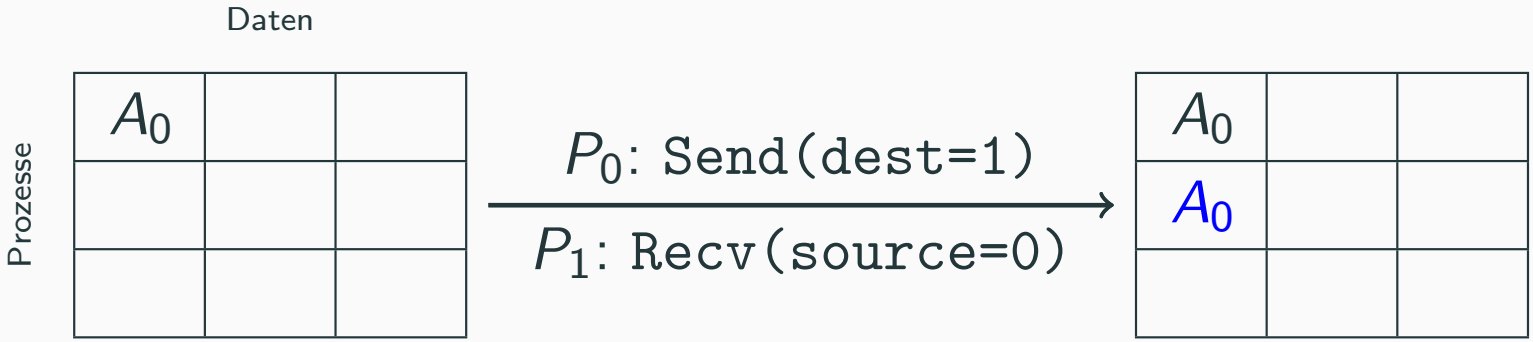

- `int MPI_Send(buf, count, datatype, dest, tag, comm)`
- `int MPI_Recv(buf, count, datatype, source, tag, comm, status)`

Kollektive Operationen

Bcast

`Bcast` verteilt ein Datum auf alle Prozesse.

- `int MPI_Bcast(buf, count, datatype, root, comm)`
- Daten befinden sich ursprünglich auf `root`
  - $\rightsquigarrow$ Fallunterscheidung in `Bcast`:
  - `if rank == root then forall others: send() else recv()`

Bcast

`Bcast` verteilt ein Datum auf alle Prozesse.

- `int MPI_Bcast(buf, count, datatype, root, comm)`
- Daten befinden sich ursprünglich auf `root`
  - $\rightsquigarrow$ Fallunterscheidung in `Bcast`:
  - `if rank == root then forall others: send() else recv()`

Implementiert `custom_Bcast` in `demos/mpi/custom_broadcast`!

Scatter

`Scatter` verteilt eine Liste von Daten auf mehrere Prozesse.

- `int MPI_Scatter(sendbuf, sendcount, sendtype, recvbuf, recvcount, recvtype, root, comm)`
- `sendcount`, `recvcount`: Zahl der Elemente, die an einen Prozess verteilt werden
- i.d.R.: `sendcount == recvcount`

Gather

`Gather` sammelt Daten von allen Prozessen in einer Liste.

- `int MPI_Gather(sendbuf, sendcount, sendtype, recvbuf, recvcount, recvtype, root, comm)`
- `sendcount`, `recvcount`: Zahl der Elemente, die an einen Prozess verteilt werden
- i.d.R.: `sendcount == recvcount`

Scatter und Gather

`Scatter` und `Gather` sind „invers“:

```
int nums[4];
int local;
if (rank == 0) { nums = {0, 1, 2, 3}; }

MPI_Scatter(nums, 1, MPI_INT, &local, 1, MPI_INT,
    0, MPI_COMM_WORLD);
// in P_i gilt: local = i
MPI_Gather(&local, 1, MPI_INT, nums, 1, MPI_INT,
    0, MPI_COMM_WORLD);
```

Dieser Code hat keine Effekte außer Seiteneffekte.

Aufgabe zu Scatter und Gather

Implementiert folgendes Programm mit MPI:

- N: Prozessoranzahl (`MPI_Comm_size`), x: 10
- P_0 legt `long`-Liste mit Elementen $[1, 2, ..., N \cdot x]$ an
- P_i summiert einen x-Ausschnitt der Liste mit $i \in [0; N)$
- P_0 summiert die einzelnen Summen

Verwendet dafür:

- `MPI_Comm_size`, `MPI_Comm_rank`
- `MPI_Scatter`
- `MPI_Gather`

Dokumentation für MPI-Funktionen bekommt ihr mit `man <f>`

Allgather

`Allgather` ist die Verknüpfung von `Gather` und `Bcast`.

- `int MPI_Allgather(sendbuf, sendcount, sendtype, recvbuf, recvcount, recvtype, comm)`
- Im Gegensatz zu `Gather` gibt es keinen Parameter `root`

Alltoall

`Alltoall` stückelt Daten von jedem Prozess und verteilt sie.

- `int MPI_Alltoall(sendbuf, sendcount, sendtype, recvbuf, recvcount, recvtype, comm)`
- Es führt sozusagen jeder Prozess einmal `Scatter` aus

Reduce

`Reduce` wendet eine assoziative Operation auf verteilte Daten an.

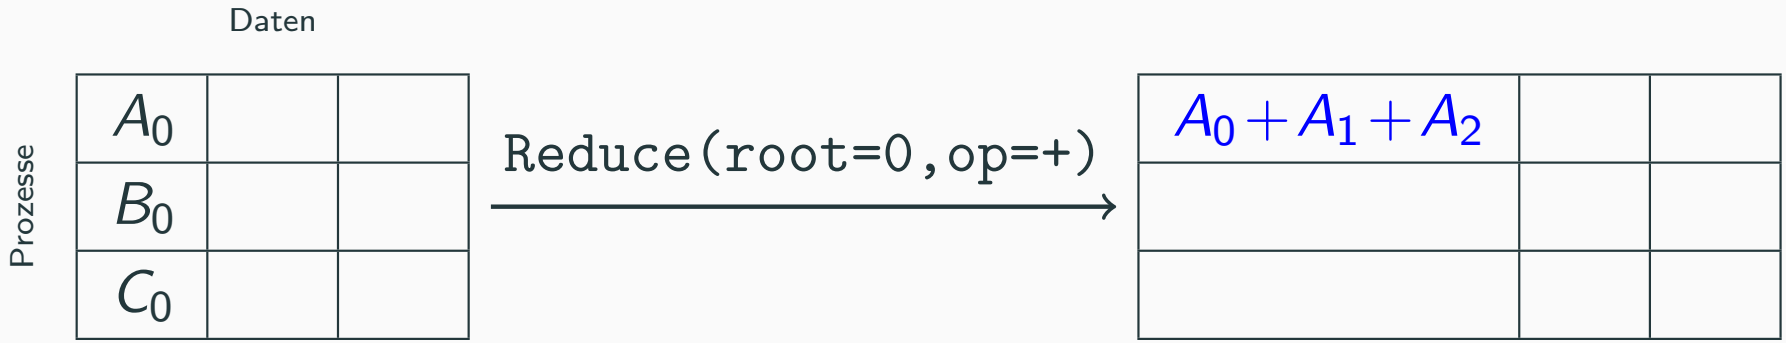

- `int MPI_Reduce(sendbuf, recvbuf, count, type, op, root, comm)`
- *Ungefähr* dasselbe wie ein Fold!

Reduce

`Reduce` wendet eine assoziative Operation auf verteilte Daten an.

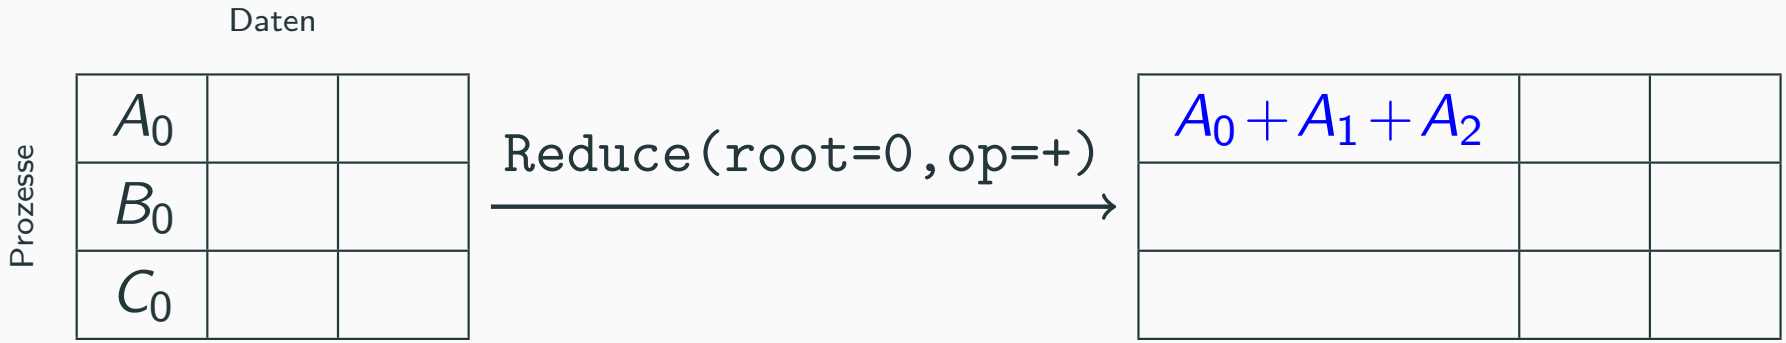

- `int MPI_Reduce(sendbuf, recvbuf, count, type, op, root, comm)`
- *Ungefähr* dasselbe wie ein Fold!
- Ersetzt den letzten Teil der Summenaufgabe durch einen Aufruf zu `Reduce`

Ende

Ende

- Im Campus-System kann man sich bis zum 17.03. für die ProPa-Klausur anmelden
- Ab Mittwoch kann man sich Rückmelden bis zum 15.02.
- Eulenfest am 23.01.!