Tutorium 13: Compiler

Paul Brinkmeier

8. Februar 2022

Tutorium Programmierparadigmen am KIT

Einführung in Compilerbau

Compiler in ProPa

- Ein bisschen...
  - Lexikalische Analyse
  - Syntaktische Analyse (Parsen)
  - Semantische Analyse, Optimierung
  - Codegenerierung

Compiler in ProPa

- Ein bisschen...
  - Lexikalische Analyse
  - Syntaktische Analyse (Parsen)
  - Semantische Analyse, Optimierung
  - Codegenerierung
- Klausur:
  - SLL(k)-Form beweisen
  - Rekursiven Abstiegsparser schreiben/vervollständigen
  - First/Follow-Mengen berechnen
  - Java-Bytecode

$$\mathit{SGML} \rightarrow \texttt{<}\ \texttt{id}\ \texttt{>}\ \ \mathit{Children}\ \ \texttt{<}\ \texttt{/}\ \texttt{>}$$

$$\mathit{Children} \rightarrow \epsilon \mid \mathit{SGML}\ \ \mathit{Children}$$

$$\{\texttt{<id><id></><id></></>},\ \ \texttt{<id></>},\ \ \ldots\} \in G$$

$$\mathit{SGML} \rightarrow \texttt{<}\ \texttt{id}\ \texttt{>}\ \ \mathit{Children}\ \ \texttt{<}\ \texttt{/}\ \texttt{>}$$

$$\mathit{Children} \rightarrow \epsilon \mid \mathit{SGML}\ \ \mathit{Children}$$

$$\{\texttt{<id><id></><id></></>},\ \ \texttt{<id></>},\ \ ...\} \in G$$

- Begründen Sie formal, dass die obige Grammatik nicht in $\mathrm{SLL}(1)$-Form ist (3P.).

$$\textit{SGML} \rightarrow \texttt{<}\ \texttt{id}\ \texttt{>}\ \textit{Children}\ \texttt{<}\ \texttt{/}\ \texttt{>}$$

$$\textit{Children} \rightarrow \epsilon \mid \textit{SGML}\ \ \textit{Children}$$

$$\{\texttt{<id><id></><id></></>},\ \ \texttt{<id></>},\ \ ...\} \in G$$

- Begründen Sie formal, dass die obige Grammatik nicht in $\mathrm{SLL}(1)$-Form ist (3P.).
- Entwickeln Sie für [eine linksfaktorisierte Version der obigen Grammatik] einen rekursiven Abstiegsparser (16P.).

Java-Bytecode (16SS)

Übersetzen Sie folgenden Java-Programmausschnitt in Java-Bytecode (10P.):

```
if (((a < b) || !((a < c) || (c < b))) && !(c < 0)) {
    c = b + a;
}
```

Java-Bytecode (16SS)

Übersetzen Sie folgenden Java-Programmausschnitt in Java-Bytecode (10P.):

```
if (((a < b) || !((a < c) || (c < b))) && !(c < 0)) {
    c = b + a;
}
```

Hinweise:

- Codeerzeugung für bedingte Sprünge: Folien 447ff.
- Um eine Bedingung der Form `!cond` zu übersetzen, reicht es, `cond` zu übersetzen und die Sprungziele anzupassen.

Compiler

Compiler: Motivation

- Maschine(-nmodell) versteht i.d.R. eingeschränkten Instruktionssatz
- $\leadsto$ Programme in Maschinensprache sind schwer les-/schreibbar

Compiler: Motivation

- Maschine(-nmodell) versteht i.d.R. eingeschränkten Instruktionssatz
- $\leadsto$ Programme in Maschinensprache sind schwer les-/schreibbar
- Also: Erfinde einfacher zu Schreibende ($\approx$ mächtigere) Sprache, die dann in die Sprache der Maschine übersetzt wird.
- Diesen Übersetzungsschritt sollte optimalerweise ein Programm erledigen, da wir sonst auch einfach direkt Maschinensprache-Programme schreiben können.

Compiler

- Übersetzer für formale Sprachen nennt man *Compiler*
- Beispiele:
  - C, Haskell, Rust, Go $\rightarrow$ X86
  - Java, Scala, Kotlin $\rightarrow$ Java-Bytecode
  - TypeScript $\rightarrow$ JavaScript/WebAssembly

Compiler

- Übersetzer für formale Sprachen nennt man *Compiler*
- Beispiele:
  - C, Haskell, Rust, Go $\rightarrow$ X86
  - Java, Scala, Kotlin $\rightarrow$ Java-Bytecode
  - TypeScript $\rightarrow$ JavaScript/WebAssembly
- Single-pass vs. Multi-pass
  - Single-pass: Eingabe wird einmal gelesen, Ausgabe währenddessen erzeugt (ältere Compiler)
  - Multi-pass: Eingabe wird in Zwischenschritten in verschiedene Repräsentationen umgewandelt
    - Quellsprache, Tokens, AST, Zwischensprache, Zielsprache

Lexikalische Analyse

```
int x1 = 123;
print("123");
```

```
int, id[x1], assign,
intlit[123], semi,
id[print], lp,
stringlit["123"], ...
```

- Lexikalische Analyse (Tokenisierung) verarbeitet eine Zeichensequenz in eine Liste von *Tokens*.
- Tokens sind Zeichengruppen, denen eine Semantik innewohnt:
  - `int` — Typ einer Ganzzahl
  - `=` — Zuweisungsoperator
  - `x1` — Variablen- oder Methodenname
  - `123` — Literal einer Ganzzahl
  - `"123"` — String-Literal
  - etc.
- Lösbar mit regulären Ausdrücken, Automaten

Syntaktische Analyse

- Syntaktische Analyse stellt die unterliegende (Baum-)Struktur der bisher linear gelesenen Eingabe fest:
  - Blockstruktur von Programmen
  - Baumstruktur von HTML-Dateien
  - Header + Inhalt-Struktur von Mails
  - Verschachtelte arithmetische Ausdrücke
- Syntaktische Analyse ist das größte Compiler-Thema in PP.

Syntaktische Analyse

- Syntaktische Analyse stellt die unterliegende (Baum-)Struktur der bisher linear gelesenen Eingabe fest:
  - Blockstruktur von Programmen
  - Baumstruktur von HTML-Dateien
  - Header + Inhalt-Struktur von Mails
  - Verschachtelte arithmetische Ausdrücke
- Syntaktische Analyse ist das größte Compiler-Thema in PP.
- Übliche Vorgehensweise (in PP):
  - Grammatik G erfinden
  - Ggf. G in andere Form G' bringen
  - Rekursiven Abstiegsparser für G' implementieren
- Alternativ: Parser-Kombinatoren, Yacc, etc.

Beispiel: Arithmetische Ausdrücke

`a+a+b` `a*c+b` `a*c+b*d`

- Zu beachten: Punkt-vor-Strich (Präzedenz), Klammerung, etc.
- Nicht mehr mit regulären Ausdrücken lösbar
- Beispielgrammatik:

$$
\begin{aligned}
E \rightarrow\ & E\ \texttt{+}\ E \\
\mid\ & E\ \texttt{*}\ E \\
\mid\ & \texttt{(}\ E\ \texttt{)} \\
\mid\ & \texttt{id}
\end{aligned}
$$

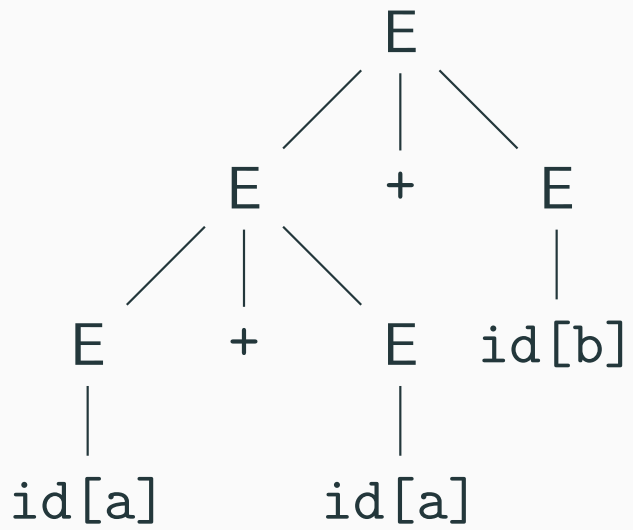

Beispiel: Arithmetische Ausdrücke

`a+a+b` `a*c+b` `a*c+b*d`

- Zu beachten: Punkt-vor-Strich (Präzedenz), Klammerung, etc.
- Nicht mehr mit regulären Ausdrücken lösbar
- Beispielgrammatik:

$$
\begin{aligned}
E \rightarrow\ & E\ \texttt{+}\ E \\
\mid\ & E\ \texttt{*}\ E \\
\mid\ & \texttt{(}\ E\ \texttt{)} \\
\mid\ & \texttt{id}
\end{aligned}
$$

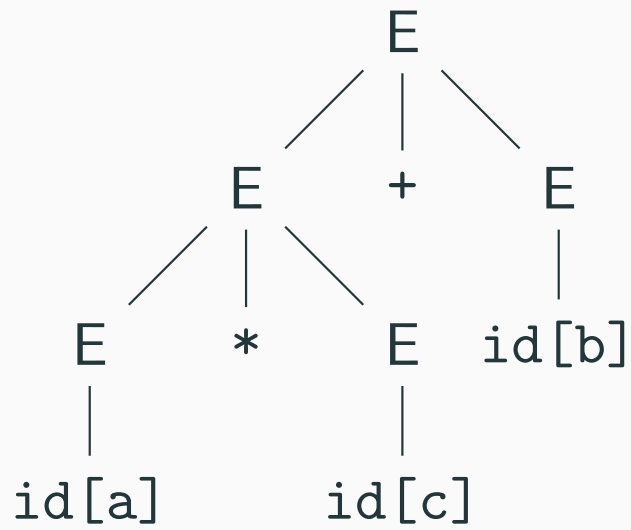

Beispiel: Arithmetische Ausdrücke

`a+a+b` `a*c+b` `a*c+b*d`

- Zu beachten: Punkt-vor-Strich (Präzedenz), Klammerung, etc.
- Nicht mehr mit regulären Ausdrücken lösbar
- Beispielgrammatik:

$$
\begin{aligned}
E \rightarrow\ & E\ \texttt{+}\ E \\
\mid\ & E\ \texttt{*}\ E \\
\mid\ & \texttt{(}\ E\ \texttt{)} \\
\mid\ & \texttt{id}
\end{aligned}
$$

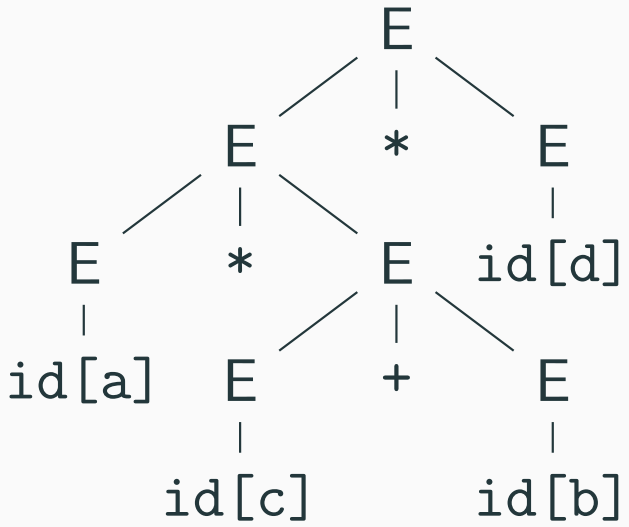

Beispiel: Mathematische Ausdrücke

$$E \rightarrow E \texttt{ + } E \mid E \texttt{ * } E \mid \texttt{(} E \texttt{)} \mid \texttt{id}$$

```
a*c+b
```

Beispiel: Mathematische Ausdrücke

$$E \rightarrow E \texttt{ + } E \mid E \texttt{ * } E \mid \texttt{(} E \texttt{)} \mid \texttt{id}$$

a*c+b

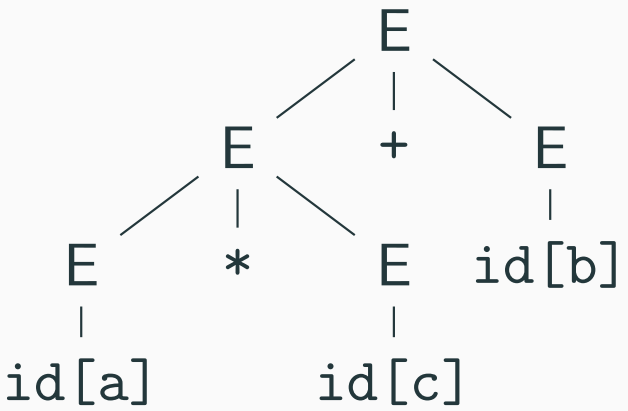

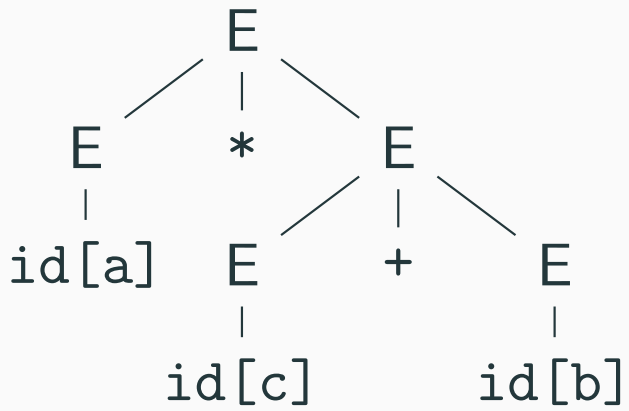

- Grammatik nicht eindeutig $\rightsquigarrow$ schlecht
- Grammatik garantiert nicht Punkt-vor-Strich $\rightsquigarrow$ schlecht
- Grammatik ist linksrekursiv $\rightsquigarrow$ nicht einfach zu parsen $\rightsquigarrow$ schlecht

Grammar Engineering 1 — Präzedenz

$$E \rightarrow E \texttt{ + } E \mid E \texttt{ * } E \mid \texttt{(} E \texttt{)} \mid \texttt{id}$$

- Punkt-vor-Strich („Operatorpräzedenz“) wird von dieser naiven Grammatik nicht beachtet.
- Lösung: Ein Nichtterminal pro Präzedenzstufe:
  - *Summen* von *Produkten* von *Atomen*.
  - Herkömmliche Begriffe: Ausdruck, Term und Faktor.

$$\begin{aligned} \mathit{Expr} &\rightarrow \mathit{Expr} \texttt{ + } \mathit{Term} \\ &\mid \mathit{Term} \\ \mathit{Term} &\rightarrow \mathit{Term} \texttt{ + } \mathit{Factor} \\ &\mid \mathit{Factor} \\ \mathit{Factor} &\rightarrow \texttt{(} \mathit{Expr} \texttt{)} \mid \texttt{id} \end{aligned}$$

Welche Art von Grammatik wollen wir denn genau?

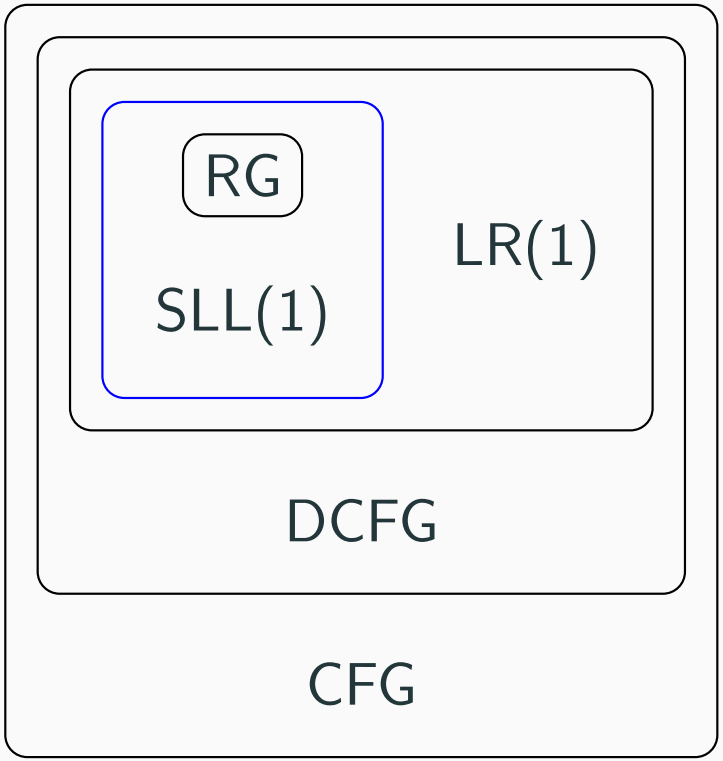

- CFG-Parsen ist i.A. in $O(n^3)$, bspw. Earley-Algorithmus.
- Reguläre Grammatiken ($\approx$ reg. Sprachen) sind uns nicht mächtig genug.
- LR: Left-to-right, Rightmost
- LL: Left-to-right, Leftmost
- SLL-Parsing $\in O(n)$

CFG: Context-Free Grammar/Kontextfreie Grammatik

Grammar Engineering 2 — Linksrekursion eliminieren

$$
\begin{aligned}
\mathit{Expr} &\to \mathit{Expr} + \mathit{Term} \\
&\mid \mathit{Term} \\
\mathit{Term} &\to \mathit{Term} + \mathit{Factor} \\
&\mid \mathit{Factor} \\
\mathit{Factor} &\to (\ \mathit{Expr}\ ) \mid \texttt{id}
\end{aligned}
$$

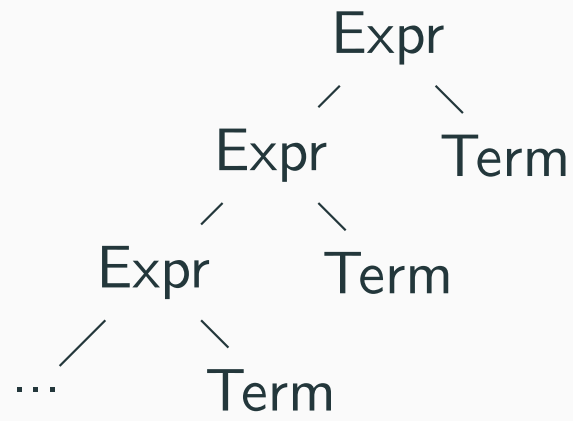

Problem: Die Linksableitung des Symbols *Expr* in dieser Grammatik ist eine endlose Schleife.

Grammar Engineering 2 — Linksrekursion eliminieren

$$
\begin{aligned}
\mathit{Expr} &\to \mathit{Expr} \texttt{ + } \mathit{Term} \\
&\mid \mathit{Term} \\
\mathit{Term} &\to \mathit{Term} \texttt{ + } \mathit{Factor} \\
&\mid \mathit{Factor} \\
\mathit{Factor} &\to \texttt{(} \mathit{Expr} \texttt{)} \mid \texttt{id}
\end{aligned}
$$

$$
\begin{aligned}
\mathit{Expr} &\to \mathit{Term}\ \mathit{Expr}' \\
\mathit{Expr}' &\to \texttt{+ } \mathit{Term}\ \mathit{Expr}' \\
&\mid \epsilon \\
\mathit{Term} &\to \mathit{Term}\ \mathit{Expr}' \\
\mathit{Term}' &\to \texttt{* } \mathit{Factor}\ \mathit{Term}' \\
&\mid \epsilon \\
\mathit{Factor} &\to \texttt{(} \mathit{Expr} \texttt{)} \mid \texttt{id}
\end{aligned}
$$

Lösung: Linksrekursion eliminieren, durch folgendes Umschreiben der Grammatik:

Grammar Engineering 2 — Linksrekursion eliminieren

$$
\begin{aligned}
\mathit{Expr} &\to \mathit{Expr}\ \texttt{+}\ \mathit{Term} \\
&\mid \mathit{Term} \\
\mathit{Term} &\to \mathit{Term}\ \texttt{+}\ \mathit{Factor} \\
&\mid \mathit{Factor} \\
\mathit{Factor} &\to \texttt{(}\ \mathit{Expr}\ \texttt{)} \mid \texttt{id}
\end{aligned}
$$

$$
\begin{aligned}
\mathit{Expr} &\to \mathit{Term}\ \mathit{Expr}' \\
\mathit{Expr}' &\to \texttt{+}\ \mathit{Term}\ \mathit{Expr}' \\
&\mid \epsilon \\
\mathit{Term} &\to \mathit{Term}\ \mathit{Expr}' \\
\mathit{Term}' &\to \texttt{*}\ \mathit{Factor}\ \mathit{Term}' \\
&\mid \epsilon \\
\mathit{Factor} &\to \texttt{(}\ \mathit{Expr}\ \texttt{)} \mid \texttt{id}
\end{aligned}
$$

$$
\begin{aligned}
\mathit{Sym} &\to \mathit{Sym}\ \alpha \\
&\mid \beta
\end{aligned}
$$

$$
\begin{aligned}
\mathit{Sym} &\to \beta\ \mathit{Sym}' \\
\mathit{Sym}' &\to \alpha\ \mathit{Sym}' \\
&\mid \epsilon
\end{aligned}
$$

Verbesserte Grammatik

$$
\begin{aligned}
E &\to T\ EList \\
EList &\to \texttt{+}\ T\ EList \\
&\mid \epsilon \\
T &\to T\ EList \\
TList &\to \texttt{*}\ F\ TList \\
&\mid \epsilon \\
F &\to \texttt{(}\ E\ \texttt{)} \mid \texttt{id}
\end{aligned}
$$

- Grammatik ist eindeutig ✓
- Grammatik erzeugt nur korrekte Terme ✓
- Grammatik enthält keine Linksrekursion ✓

First-/Followmenge, Indizmenge

$$\mathit{EList} \rightarrow \epsilon \mid \texttt{+}\ \ T\ \ \mathit{EList} \mid \texttt{-}\ \ T\ \ \mathit{EList}$$

Wie können wir bspw. bei *EList* entscheiden, welche Produktion anzuwenden ist?

First-/Followmenge, Indizmenge

$$\mathit{EList} \rightarrow \epsilon \mid \texttt{+}\ \ T\ \ \mathit{EList} \mid \texttt{-}\ \ T\ \ \mathit{EList}$$

Wie können wir bspw. bei *EList* entscheiden, welche Produktion anzuwenden ist?

- $\rightsquigarrow$ definiere *Indizmenge* $IM_k(A \rightarrow \alpha) = \mathrm{First}_k(\alpha \mathrm{Follow}_k(A))$
- Wenn nächste k Token in $IM_k(\mathit{EList} \rightarrow \phi) \rightsquigarrow$ weiter mit ϕ

First-/Followmenge, Indizmenge

$$\mathit{EList} \rightarrow \epsilon \mid \texttt{+}\ \ T\ \ \mathit{EList} \mid \texttt{-}\ \ T\ \ \mathit{EList}$$

Wie können wir bspw. bei *EList* entscheiden, welche Produktion anzuwenden ist?

- $\rightsquigarrow$ definiere *Indizmenge* $IM_k(A \rightarrow \alpha) = \mathrm{First}_k(\alpha \mathrm{Follow}_k(A))$
- Wenn nächste k Token in $IM_k(\mathit{EList} \rightarrow \phi) \rightsquigarrow$ weiter mit ϕ
- $IM_1(\mathit{EList} \rightarrow \epsilon) = \mathrm{First}_1(\epsilon \mathrm{Follow}_1(\mathit{EList})) = \{), \#\}$
- $IM_1(\mathit{EList} \rightarrow \texttt{+}\ \ T\ \ \mathit{EList}) = \mathrm{First}_1(\texttt{+}\ T\ \mathit{EList}\ \mathrm{Follow}_1(\mathit{EList})) = \{\texttt{+}\}$
- $IM_1(\mathit{EList} \rightarrow \texttt{-}\ \ T\ \ \mathit{EList}) = \mathrm{First}_1(\texttt{-}\ T\ \mathit{EList}\ \mathrm{Follow}_1(\mathit{EList})) = \{\texttt{-}\}$

First-/Followmenge, Indizmenge

$$\mathit{EList} \rightarrow \ \epsilon \mid \texttt{+} \ \ T \ \ \mathit{EList} \mid \texttt{-} \ \ T \ \ \mathit{EList}$$

Wie können wir bspw. bei *EList* entscheiden, welche Produktion anzuwenden ist?

- $\rightsquigarrow$ definiere *Indizmenge* $\mathit{IM}_k(A \rightarrow \alpha) = \mathrm{First}_k(\alpha \mathrm{Follow}_k(A))$
- Wenn nächste k Token in $\mathit{IM}_k(\mathit{EList} \rightarrow \phi) \rightsquigarrow$ weiter mit ϕ
- $\mathit{IM}_1(\mathit{EList} \rightarrow \ \epsilon) = \mathrm{First}_1(\epsilon \mathrm{Follow}_1(\mathit{EList})) = \{), \#\}$
- $\mathit{IM}_1(\mathit{EList} \rightarrow \ \texttt{+} \ \ T \ \ \mathit{EList}) = \mathrm{First}_1(\texttt{+} \ T \ \mathit{EList} \ \mathrm{Follow}_1(\mathit{EList})) = \{\texttt{+}\}$
- $\mathit{IM}_1(\mathit{EList} \rightarrow \ \texttt{-} \ \ T \ \ \mathit{EList}) = \mathrm{First}_1(\texttt{-} \ T \ \mathit{EList} \ \mathrm{Follow}_1(\mathit{EList})) = \{\texttt{-}\}$
- $\mathrm{First}_k(A)$: Menge an möglichen ersten k Token in A
- $\mathrm{Follow}_k(A)$: Menge an möglichen ersten k Token nach A

SLL-Kriterium

Grammatik ist in $\mathrm{SLL}(k)$-Form

$:\Leftrightarrow \forall A \to \alpha, A \to \beta \in P : IM_k(A \to \alpha) \cap IM_k(A \to \beta) = \emptyset$

- $\mathrm{SLL}(k)$: Bei jedem Nichtterminal muss die zu wählende Produktion an den nächsten k Token wählbar sein.
- Nichtterminale mit nur einer Produktion sind hier irrelevant
- Schwierig daran: Follow-Mengen berechnen

SLL-Kriterium

Grammatik ist in $\mathrm{SLL}(k)$-Form

$:\Leftrightarrow \forall A \to \alpha, A \to \beta \in P : IM_k(A \to \alpha) \cap IM_k(A \to \beta) = \emptyset$

- $\mathrm{SLL}(k)$: Bei jedem Nichtterminal muss die zu wählende Produktion an den nächsten k Token wählbar sein.
- Nichtterminale mit nur einer Produktion sind hier irrelevant
- Schwierig daran: Follow-Mengen berechnen

$$E \to E \texttt{ + } T \mid E \texttt{ - } T \mid T$$
$$T \to T \texttt{ * } F \mid T \texttt{ / } F \mid F$$
$$F \to \texttt{num} \mid \texttt{(} E \texttt{)}$$

- Begründet formal, dass obige Grammatik nicht $\mathrm{SLL}(1)$.
- Berechnet $\mathrm{Follow}_1(N)$ für $N \in \{E, T, F\}$.

Rekursive Abstiegsparser

$$
\begin{aligned}
E &\to T \;\; EList \\
EList &\to \epsilon \mid \texttt{+} \;\; T \;\; EList \mid \texttt{-} \;\; T \;\; EList \\
T &\to F \;\; TList \\
TList &\to \epsilon \mid \texttt{*} \;\; F \;\; TList \mid \texttt{/} \;\; F \;\; TList \\
F &\to \texttt{num} \mid \texttt{(} \;\; E \;\; \texttt{)}
\end{aligned}
$$

- Yay, unsere Grammatik hat jetzt $\mathrm{SLL}(1)$-Form!
- Aber was bringt das?

Rekursive Abstiegsparser

$$
\begin{aligned}
E &\to T \;\; EList \\
EList &\to \epsilon \mid \texttt{+} \;\; T \;\; EList \mid \texttt{-} \;\; T \;\; EList \\
T &\to F \;\; TList \\
TList &\to \epsilon \mid \texttt{*} \;\; F \;\; TList \mid \texttt{/} \;\; F \;\; TList \\
F &\to \texttt{num} \mid \texttt{(} \;\; E \;\; \texttt{)}
\end{aligned}
$$

- Yay, unsere Grammatik hat jetzt $\mathrm{SLL}(1)$-Form!
- Aber was bringt das?
- G ist jetzt einfach ausprogrammierbar:
  - 1 Methode per Nichtterminal: `parseE()`, `parseEList()`, ...
  - `Token[k]`-Instanzattribut für k langen Lookahead
  - `expect(TokenType)`-Methode, um Token zu verarbeiten

Semantische Analyse

- PP beschäftigt sich (bis auf Typinferenz) nur kurz mit semantischer Analyse
- Typchecks/-inferenz, Namensanalyse
- $\leadsto$ weiterführende (Master-)Vorlesungen am IPD

Optimierung

- Moderne Compiler haben i.d.R. (mindestens) eine Zwischensprache, bspw.
  - GCC: Generic, GIMPLE, RTL
  - LLVM, libFirm
  - GHC: Core, STG
- Vorteil: Optimierungen müssen nur einmal implementiert werden

Beispiel: GCC

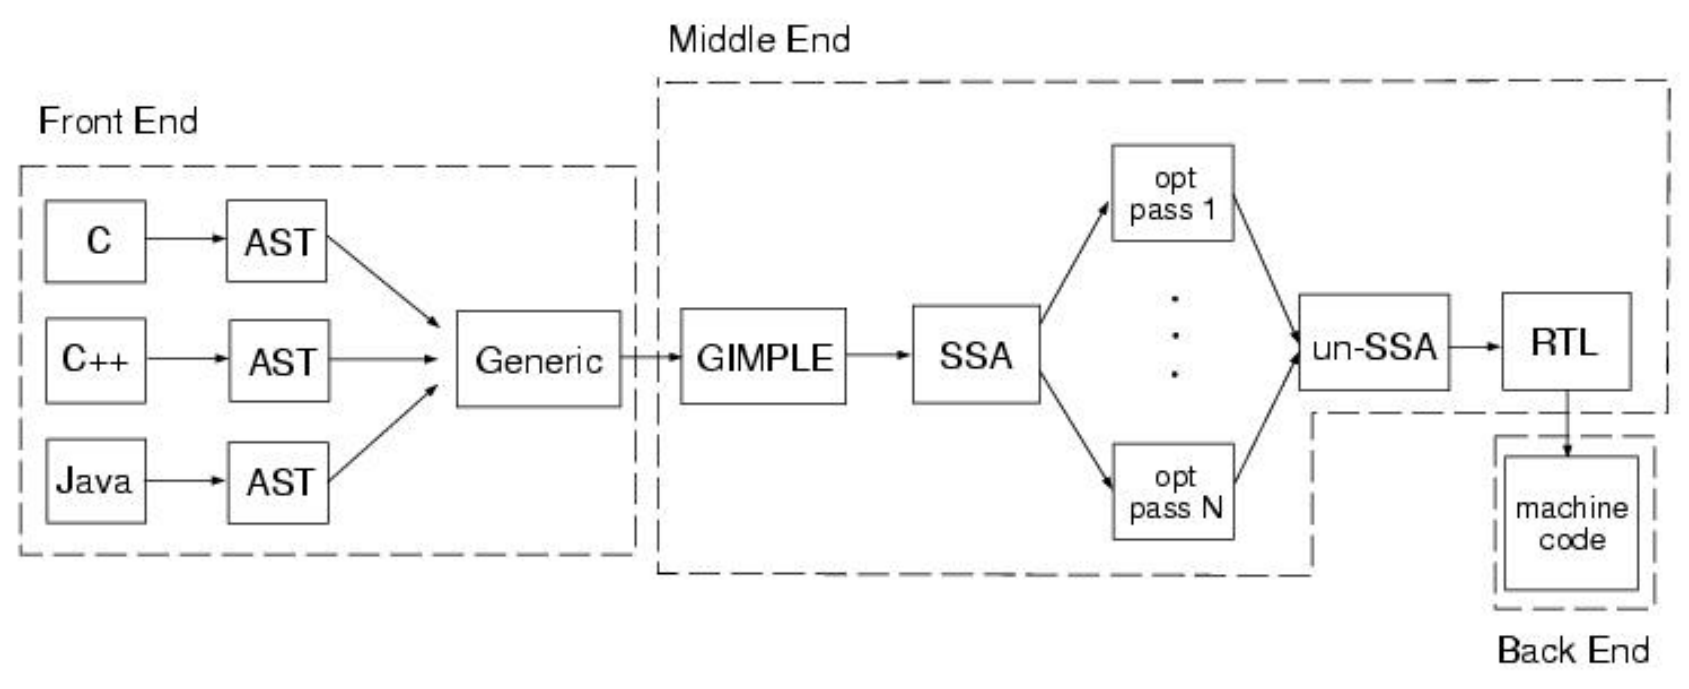

- Generic: Sprachunabhängiger Output des Frontend
- GIMPLE: Für Optimierungen (SSA: Spezielle Form)
- RTL: Für Registerallokation, Instruktionsauswahl
- Ca. 15 Mio. Zeilen Code (2019, laut Wikipedia)

Beispiel: GHC

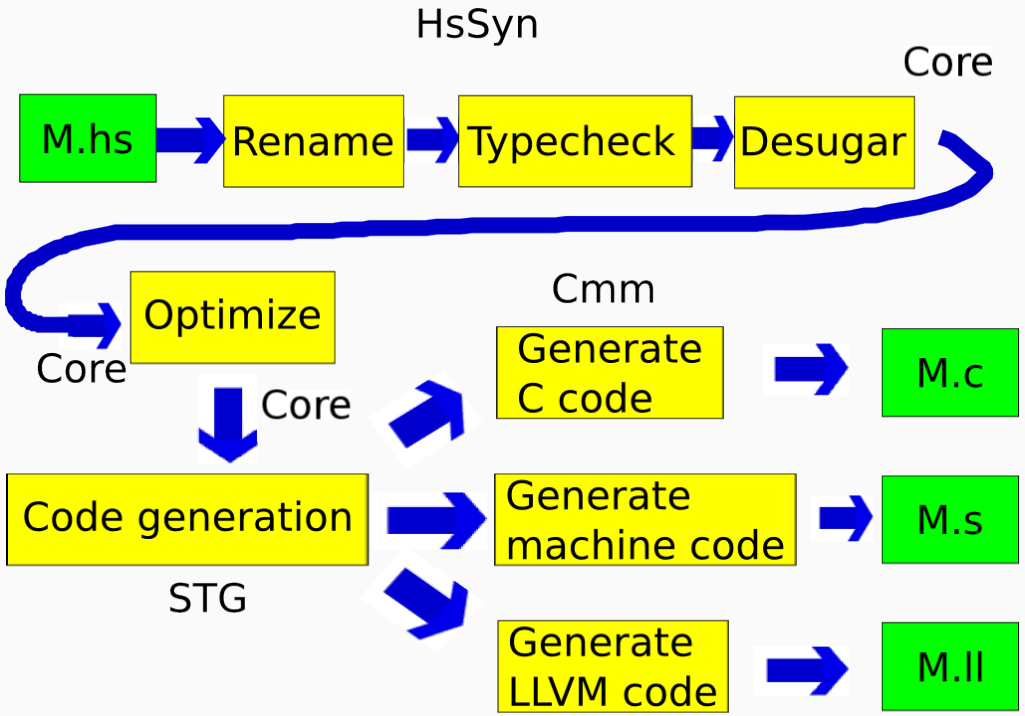

- Core: „λ-Kalkül mit Extras“, für Optimierungen
- STG: Spineless Tagless Graph-Machine, für Codeerzeugung
- Cmm: „C minus minus“, für Codeerzeugung
- Ca. 600.000 Zeilen Code, $\frac{3}{4}$ davon Haskell (selbst gezählt)

propalang

propalang

```
func factorial(n) {
  if (n == 0) {
    return 1;
  } else {
    return n * factorial(n - 1);
  }
}
```

- pbrinkmeier.de/propalang.zip
- Im Repository: demos/java/propalang
- Parser für Expressions und Statements
- Interpreter: `java Main -- run test.pp`

propalang: Aufgaben

```
func factorial(n) {
  if (n == 0) {
    return 1;
  } else {
    return n * factorial(n - 1);
  }
}
```

- Erweitert den Parser um eine Divisionsoperation /
  - `new OperatorExpression(Operator.DIVIDE, ...)`

propalang: Aufgaben

```
func factorial(n) {
  if (n == 0) {
    return 1;
  } else {
    return n * factorial(n - 1);
  }
}
```

- Erweitert den Parser um eine Divisionsoperation `/`
  - `new OperatorExpression(Operator.DIVIDE, ...)`
- Erweitert den Parser um Schleifen `while` und `for`
  - `while (condition) loopStmt;`
  - `for (init; condition; post) loopStmt;`
  - `new WhileStatement(...)`
  - Keine neue AST-Klasse für `for`!

Ende

Letzte Folie

- Morgen, Mi, 09.02. um 14:00: Letzte Vorlesung
- ÜB-Korrekturen: Bis spätestens Ende Februar
- Klausur: 08.04.2022, 12:00
- Tutoriumsfolien, -code, etc.: github.com/pbrinkmeier/pp-tut
- Fragen auch gerne an `pp-tut@pbrinkmeier.de` :)

Danke fürs Kommen und eine gute Prüfungsphase!